2P-08

感情分析に用いる感情辞書の自動構築手法の検討

大澤　泰我†　　マッキン ケネスジェームス†　永井　保夫†
東京情報大学†

1. はじめに

近年,テキスト（単語・文・文章）に対する感情情報処理[1]が注目を集めている.その一例として特定の文が「喜怒哀楽」どの感情に当たるかを推定する研究がある[2].テキストから感情を判断するためには,テキストがどの感情に当たるのかを定義した感情辞書が必要になる.そこで,研究者の主観を排除でき,メンテナンスの容易な自動の感情辞書構築が求められている[3].

従来では,人手によりテキストがどの感情に当たるのかを定義し,感情辞書の構築を行っている.しかし,人手を用いた辞書構築手法では,多くの時間とコスト（労力・手間）が必要となる.そのため本研究では,まずSNS上から顔文字付きの文章データを収集し,顔文字に対応する感情表現を正解ラベルとする.次に顔文字を除いた文章データとともに,記録したデータセットを感情辞書とすることで,感情辞書の自動構築を行っている[8].

本論文では,人手を用いて作られた感情辞書と,本研究の自動構築された感情辞書を用いて,感情分析のための分類器を作成し,分類器の正解率を比較する.

2. 感情分析に用いる感情辞書の構築

テキストから感情を判断するためには,感情を含んだ単語や文章がどの感情に当たるかを定義したものが必要となる.本論文では,感情極性分類用の感情辞書を用いる.感情極性分類では,最もシンプルな感情モデルであるネガティブとポジティブ(感情極性)を扱う.

2.1 人手による感情辞書の構築

小林[4]らは,約5千件の用言に単語感情極性対応表[5]を用いて,評価極性情報を各用語に付与した,日本語評価極性辞書を構築した.表1の日本語評価極性辞書は,「ネガティブ,機嫌を損ねる」のようにラベル（感情極性）と用語データ（単語・文）から構成されている.

Suzuki[6]らは,2015年から2016年ごろのTwitter文章を対象に,Twitter日本語評判分析データセットを構築した.Twitter日本語評判分析データセットは,最低4名以上の作業者により評価を行い,多数決により各文章（ツイートID）にネガティブ,ポジティブ,ニュートラル,無関係の4つの感情表現を付与している.表1のTwitter日本語評判分析データセットは,「ポジティブ,コンビニでプリントアウト、簡単スピーディで宜しいじゃないか。確認には十分。」のようにラベルと文章（1つのデータセット中に複数の文が存在する）データから構成されている.

本論文では比較のため,日本語評価極性辞書に合わせた,ネガティブ,ポジティブのみ付与された文章データ約3万件のTwitter日本語評判分析データセットを利用する.

Twitter日本語評判分析データセットには,著作権などの理由により,ツイートIDを本文の代わりに収録している.そのため,各ツイート文章は再取得が必要である.

表１　人手により構築された感情辞書

	日本語評価極性辞書[4]	Twitter日本語評判分析データセット[6]
作成方法	単語感情極性対応表[5]を元にしたラベリング	4名以上の作業者による多数決で決定したラベルを採用
件数	約5千	約3万
辞書内容	ラベル,用語（単語・文）	ラベル,文章

2.2 感情辞書構築の自動化手法の提案

本研究では,Plutchikの感情の輪[7]を元に8つの感情分類（喜び,信頼,恐れ,驚き,悲しみ,嫌悪,怒り,期待）を感情モデルとして採用している.

我々は,Twitter APIを利用し表2に示される顔文字付きの文章をTwitter（SNS）から取得している.

表２　感情表現の決定に利用した顔文字

喜び	(≧▽≦) (^^)
信頼	ε-(´∀｀*) (；´？｀)
恐れ	ｶﾞｸｶﾞｸ(((；`Д´)))ﾌﾞﾙﾌﾞﾙ Σ(°△°|||)
驚き	Σ(=ﾟωﾟ=;)ﾏｼﾞ!? Σ(ﾟДﾟ)ｱｧ!?
悲しみ	(ノ_・、)ｼｸｼｸ (ρ゜∩゜)ｸﾞｽﾝ
嫌悪	(　´_ゝ`)ﾌｰﾝ (ノ_-;)ﾊｧ…
怒り	むっ・・・　(￣∩￣# ﾑｶﾑｶ…((o(-´ -；)
期待	((o(^∇^)o))わくわく ♪((O(ゞ⌒∇⌒ゞ)O))♪ﾄﾞｷﾄﾞｷ

本研究では,SNSから顔文字付きの文章を集め,顔文字（表2）に対応する感情表現を正解ラベルとし,顔文字や不要な情報（表3）を除いた文章データとともに記録したデータセットを感情辞書としている.

表3　データセットの加工

原文	#test @you ありがとうございます！(^^) http://test.com
加工後	喜び,ありがとう ござい ます！

本研究の感情辞書は,取得したTwitterの文章の顔文字から求められる感情表現と,顔文字を除去したTwitterの文章のペアから構築される.

感情辞書は約7万件の文章データを取得し,多くの文書に共通して出現する重要度の低い単語や,重複データなどを省いた58,619件の文章から構成されている.

本研究では表2に示すような,8分類用の感情辞書を構築している.本論文では感情極性分類での比較を行うため,本研究の感情辞書を日本語評価極性辞書に合わせた,感情極性とした.各感情表現（8つの感情ラベル）は,ネガティブ（恐れ,驚き,悲しみ,嫌悪,怒り）とポジティブ（喜び,信頼,期待）の感情極性に分けた.

Automatic Construction of Emotion Dictionary for Emotion Analysis.
Taiga Ohsawa†,Kenneth J Mackin†,Yasuo Nagai†
†Tokyo University of Information Sciences

Copyright ©2022 Information Processing Society of Japan.
All Rights Reserved.

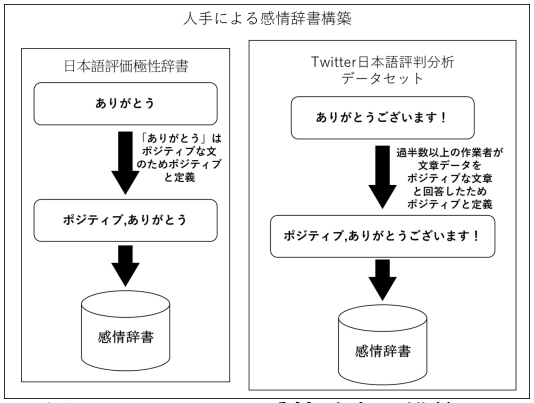


図1　人手による感情辞書の構築

従来では,図1のように人手によりテキストがどの感情に当たるかを定義し,感情辞書の構築を行っている.しかし,人手を用いた辞書構築手法では,多くの時間とコスト（労力・手間）が必要となる.また,人手を用いた感情辞書は,必要な感情表現が増えた際や再構築の際に,再度人手で作成しないといけないため,メンテナンスも容易ではない.そこで,研究者の主観を排除でき,メンテナンスの容易な自動の感情辞書構築が求められている.

本研究の感情辞書は,顔文字付きの文章データを集め,各文章データに対して,表3のように顔文字による感情表現の定義を行っている.これにより人手を用いない感情辞書の自動構築を実現している.そのため感情モデルが変わった場合やデータセットが足りない場合など,必要な状態に応じて感情辞書を自動的に構築することが可能である.

しかし,感情辞書の自動構築手法は,手法の特性上辞書の品質を低下させると考えられる.自動構築辞書は,1つ1つの文章データに対して,人手による厳密なチェックが行われていないため,重複データや余分なデータが含まれてしまう.そのため表3のようなデータセットの加工手法や重複データを省く必要がある.

3. 感情分析による提案手法の評価実験

本論文では,人手を用いて作られた感情辞書と,本研究の自動構築された感情辞書を用いて,感情分析のための分類器を作成し,その分類器の正解率を比較する.また,感情辞書比較のため,形態素解析,ベクトル化,学習モデルは本研究の手法を適用し比較する.

本研究の感情分析手法では,LSTMネットワーク[8]を用いて感情辞書を学習し,構築した学習モデルを用いて感情分析を行う.感情辞書の各文章に対応する感情表現を正解データとして学習させる.

感情分析において日本語を扱う場合,形態素解析が必要となる.そのため,各感情辞書の形態素解析には,形態素解析ツールMeCab[9]を使用する.また,自然言語を機械学習で扱う場合,何らかの方法で文章をベクトルデータに変換するベクトル化手法が必要となる.そこでベクトル化には,与えられた単語（語彙）に対して順番に数字を割り当てる最もシンプルな手法を用いる.

本研究の分類手法を用いて,各感情辞書を適用した分類器の正解率を表5に示す.

表5　各感情辞書を用いた分類器の正解率

	日本語評価極性辞書[4]	Twitter日本語評判分析データセット[6]	自動構築辞書
正解率	82.4%	86.3%	83.2%
分類数	2分類用	2分類(3分類用)	2分類(8分類用)
作成方法	人手によるラベリング	人手によるラベリング	自動ラベリング
件数	約5千	約3万(利用可能)	約7万

本研究における自動構築した辞書を利用した分類器は,従来の人手を用いて構築した辞書とほぼ同等の正解率を出すことができた.

本研究の自動構築手法を用いて構築された感情辞書は,従来手法の人手による感情辞書に比べて,短期間でデータ件数の多い辞書を作ることが可能である.また,感情モデルが違っても,その感情に対応した顔文字を用意することで,比較的簡単に多くのデータを収集することができる.

4. おわりに

本論文では,人手を用いて作られた感情辞書と,本研究の自動構築された感情辞書を用いて,感情分析のための分類器を作成し,分類器の正解率を比較した.

本研究における自動構築した辞書を利用した分類器は,従来の大規模な被験者実験を用いた手法とほぼ同等の正解率を出すことができた.

本研究の自動構築手法は従来手法に比べて,短期間でデータ件数の多い辞書を作ることが可能である.また,感情モデルが違ってもその感情に対応した顔文字を用意することで,比較的簡単に多くのデータを収集できるので,メンテナンスも容易である.そのため,研究者の主観を排除し自動の感情辞書構築が可能だと考える.

今後は,複数の感情表現を用いた感情分析を行う際に,感情極性分類を組み合わせることを考えている.これにより,分類範囲を絞り,複数の感情表現を用いた感情分析を行う際の分類器の精度向上を目指していく.

参考文献

[1] 井口征士.感性情報処理が目指すもの.情報処理,pp.792-798.(1994).
[2] 上月悠也,波多野賢治.心理学定義に基づいた感情辞書構築とその評価.情報処理学会第77国大会.3N-03,(2015).
[3] 熊本忠彦,田中克己.Web ニュース記事からの喜怒哀楽抽出.情報処理学会研究報告,pp.15-20.NL-165,(2005).
[4] 小林のぞみ,乾健太郎,松本裕治,立石健二,福島俊一.意見抽出のための評価表現の収集.自然言語処理,Vol.12,No.3,pp.203-222,(2005).
[5] Hiroya Takamura,Takashi Inui,Manabu Okumura. Extracting Semantic Orientations of Words using Spin Model.In Proceedings of the 43rd Annual Meeting of the Association for Computational Linguistics, pages.133-140,(2005).
[6] Yu Suzuki.Filtering Method for Twitter Streaming Data Using Human-in-the-Loop Machine Learning.Journal of Information Processing,Vol.27,pp.404-410,(2019).
[7] Robert Plutchik.“The nature of emotions”. American Scientist.Vol.89.Iss.4,pp.344-350,(2001).
[8] 大澤泰我,ケネス マッキン,永井保夫.文脈から感情を分析するための感情判断器の検討.第19回情報科学技術フォーラム.F-026,(2020).
[9] MeCab.https://taku910.github.io/mecab/.

Copyright ©2022 Information Processing Society of Japan.
All Rights Reserved.